Modelado supervisado con regresion multiple

Estimacion de la fraccion pulmonar de referencia a partir de descriptores de la segmentacion automatica

Juanita Trujillo Narvaez. Cod: 1000099467
Karol Isabella Martinez Villarreal. Cod: 1000099682

Ingenieria Biomedica

PSIM - 2026II - 80
Docente: Ing. Pablo Eduardo Caicedo-Rodriguez. Ph.D.

Fecha de entrega: 15 de octubre de 2026

Índice

1. Pregunta y continuidad con el analisis exploratorio **3**

2. Datos y particiones **3**

3. Metodo **5**

4. Practica comun con datos sinteticos **5**

5. Resultados del proyecto **6**

5.1. Seleccion en validacion 6

5.2. Evaluacion unica en prueba 8

6. Discusion y limites **8**

7. Reproduccion y comprobaciones **9**

8. Conclusion **10**

Resumen

Este laboratorio extiende la tabla de caracteristicas del analisis exploratorio con un modelo supervisado. Se pregunta si los descriptores de la segmentacion automatica sin realce y con umbral adaptativo permiten estimar la fraccion pulmonar que mide la mascara de referencia trazada por personas, en pacientes que el modelo no uso para ajustar sus parametros. Se comparan la regresion multiple de grado 1 y su extension polinomica de grado 2 con tres predictores, frente a la media de entrenamiento como referencia sencilla. El modelo de Grado 2, elegido por RMSE de validacion, alcanzo en la prueba de 99 pacientes un RMSE de 0.0312 frente a 0.0552 de la referencia ($R^2 = 0{,}68$). El error fue del mismo orden en los dos origenes y sin sesgo medio apreciable, aunque Montgomery aporta pocos casos. Se incluye ademas la practica comun con datos sinteticos, en la que se desarrollan las rutas continua y binaria.

1. Pregunta y continuidad con el analisis exploratorio

El analisis exploratorio comparo nueve estrategias de segmentacion clasica y eligio `base_adap` (sin realce, umbral adaptativo) con un criterio fijado de antemano. Para cada imagen con mascara de referencia, la tabla de caracteristicas contiene cinco descriptores morfologicos calculados sobre la mascara obtenida y los mismos descriptores sobre la mascara manual.

Ese analisis describe cuanto se parecen ambos valores. Este laboratorio formula la pregunta predictiva:

> *¿Los descriptores de la segmentacion automatica permiten estimar la fraccion pulmonar de la mascara de referencia en pacientes que el modelo no ha utilizado para ajustar sus parametros?*

Cuadro 1: Contrato de modelado

Unidad independiente	paciente (`grupo_id`)
Salida	`ref_fraccion_area`, fraccion adimensional del campo irradiado
Referencia	mascara pulmonar trazada por personas (NLM)
Predictores	`fraccion_area`, `energia_wavelet_d1`, `simetria_izq_der`
Estrategia	`base_adap`, imagenes elegibles
Metrica primaria	RMSE, fijada antes de comparar
Ruta binaria	no aplica

La ruta binaria no aplica al proyecto. El proyecto no formula la deteccion de tuberculosis, y su contrato de entrada declara la etiqueta clinica como variable de control. No se crea una segunda pregunta para cumplir la actividad; ambas rutas se desarrollan en la practica comun.

2. Datos y particiones

Se conserva la particion congelada del laboratorio anterior (70/15/15 por unidad independiente, estratificada por origen y clase). Los descriptores de validacion y prueba se extrajeron con el mismo codigo del analisis exploratorio, restringido a `base_adap` y a las imagenes con mascara de referencia. Las filas de prueba se generaron **despues** de congelar el protocolo.

Una imagen es elegible si supero el control de calidad y su segmentacion produjo los dos campos pulmonares. La regla se aplica igual en las tres particiones. Las imagenes de un mismo paciente se promedian en una sola fila.

Cuadro 2: Conteos por particion

Particion	**Con mascara**	**Elegibles**	**Pacientes**
Entrenamiento	486	460	457
Validacion	110	106	106
Prueba	108	99	99

Los predictores se seleccionaron solo con entrenamiento, segun su asociacion con el objetivo, la consistencia de signo entre origenes y la redundancia entre ellos. La asociacion de Spearman con el objetivo fue 0.70 para `fraccion_area`, -0.51 para `energia_wavelet_d1` y -0.23 para `simetria_izq_der`. La Tabla 2 resume las decisiones.

Cuadro 3: Del analisis exploratorio a las decisiones de modelado

Hallazgo del EDA	**Decision**	**Comprobacion**	**Limite**
fraccion_area tiene la mayor asociación con el objetivo (Spearman 0.70; 0.66 China, 0.63 Montgomery)	Predictor principal	RMSE en validación frente a la media de entrenamiento	Comparte el denominador campo_px con el objetivo
energia_wavelet_d1 se asocia con el objetivo (-0.51) con el mismo signo en ambos orígenes y redundancia moderada con fraccion_area (-0.41)	Incluir como segundo predictor	Coeficiente y comparación de grados 1 y 2 en validación	Asociación observacional; su coeficiente no es un efecto causal
simetria_izq_der tiene asociación débil (-0.23) pero de signo consistente	Incluir como tercer predictor	Se reporta aunque no mejore el RMSE de validación	Su aporte puede ser nulo
compacidad no se asocia con el objetivo y relacion_aspecto invierte su signo entre orígenes	Excluir ambos	Ninguna adicional; la exclusión queda registrada en el contrato	Una relación no lineal o condicional al centro no se explora
ref_fraccion_area es mayor en Montgomery (0.317) que en Shenzhen (0.260)	No usar el origen como predictor; reportar errores por origen	Residuos por dataset_id en validación y prueba	Montgomery aporta solo 20 imágenes en validación y en prueba; no se verifica transporte a otro centro
Las columnas ref_, err_, dice y jaccard derivan de la máscara manual	Excluirlas como predictores	Prueba automática que falla si aparecen entre los predictores	El modelo solo usa información disponible sin máscara manual
Dos pacientes aportan varias imágenes (5 imágenes en 2 grupos)	Agregar por grupo_id con la media	Prueba que falla si un grupo se repite o cruza particiones	Pérdida mínima de información (3 filas)
Las segmentaciones con una sola componente no son elegibles (26 en train, 4 en validación)	Aplicar la misma regla de elegibilidad en todas las particiones	Conteos de elegibles por partición	El modelo no aplica cuando la segmentación automática falla

3. Metodo

Sea $z_j = (x_j - \bar{x}_j)/s_j$ el predictor j estandarizado con la media y la desviacion estandar de entrenamiento. Los candidatos son:

$$\text{Grado 1:} \quad \hat{y} = \beta_0 + \sum_{j=1}^{3} \beta_j z_j, \tag{1}$$

$$\text{Grado 2:} \quad \hat{y} = \beta_0 + \sum_{j=1}^{3} \beta_j z_j + \sum_{j=1}^{3} \sum_{k=j}^{3} \beta_{jk}\, z_j z_k. \tag{2}$$

El modelo de grado 2 tiene nueve terminos mas el intercepto. Es no lineal en los predictores y lineal en los coeficientes, que se estiman por minimos cuadrados. La imputacion por mediana, el escalamiento y la expansion se ajustan dentro de un *pipeline* solo con entrenamiento.

La referencia sencilla es la media de entrenamiento; la mediana se reporta como referencia adicional. La metrica primaria es RMSE $= \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}$, en las mismas unidades de la salida; se reportan tambien MAE y R^2. El candidato se elige por menor RMSE de validacion. Despues, el protocolo se congela y la prueba se evalua una sola vez, reconstruyendo el ajuste desde entrenamiento y verificando que los coeficientes coinciden con los congelados.

4. Practica comun con datos sinteticos

La practica usa 240 sujetos simulados con tres descriptores y dos salidas generadas por mecanismos conocidos. No son imagenes reales ni diagnosticos.

En la ruta continua, el modelo de Grado 2 reconoce el termino cuadratico del mecanismo. Obtuvo un RMSE de 1.306 en validacion y 1.327 en prueba, frente a 3.872 de la referencia. El RMSE no llega a cero por el ruido aleatorio incluido en la simulacion.

En la ruta binaria, Logistica C=1.0 alcanzo en prueba un ROC-AUC de 0.81 y un AP de 0.73, frente a una prevalencia de 0.42. Con el umbral de referencia 0.5, la sensibilidad fue 0.45 y la especificidad 0.86. Una probabilidad correcta no clasifica todos los casos, porque la clase se genera por un sorteo de Bernoulli. Cambiar el umbral o C despues de mirar la prueba la convertiria en otra validacion.

Cuadro 4: Practica comun, ruta continua (datos sinteticos, unidades arbitrarias)

Poblacion	**Modelo**	**MAE**	**RMSE**	**R2**
Validacion	Grado 1	1.4182	2.0225	0.6234
Validacion	Grado 2	1.0248	1.3055	0.8431
Validacion	Referencia constante	2.5192	3.2980	-0.0014
Prueba	Grado 2	1.0504	1.3267	0.8826
Prueba	Referencia constante	2.8056	3.8719	-0.0001

Cuadro 5: Practica comun, ruta binaria (datos sinteticos, umbral 0.5)

Poblacion	Modelo	ROC-AUC	AP	Brier	Sens.	Espec.
Validacion	Logistica C=0.1	0.8861	0.8544	0.1382	0.7059	0.9032
Validacion	Logistica C=1.0	0.8880	0.8551	0.1254	0.7059	0.8710
Validacion	Referencia constante	0.5000	0.3542	0.2318	0.0000	1.0000
Prueba	Logistica C=1.0	0.8071	0.7269	0.1909	0.4500	0.8571
Prueba	Referencia constante	0.5000	0.4167	0.2431	0.0000	1.0000

5. Resultados del proyecto

5.1. Seleccion en validacion

El modelo de grado 2 obtuvo el menor RMSE de validacion (0.0334), frente a 0.0368 del grado 1 y 0.0593 de la media. La ventaja de la extension polinomica es modesta: la mayor parte del poder predictivo ya esta en el modelo lineal. La matriz de diseno tiene rango completo (10/10) y numero de condicion 8.7, de modo que los coeficientes son identificables.

Cuadro 6: Metricas en validacion por modelo y origen (fraccion adimensional)

Modelo	Origen	n	MAE	RMSE	R2
Grado 1	Todos	106	0.0286	0.0368	0.6140
Grado 1	Shenzhen	86	0.0287	0.0373	0.5421
Grado 1	Montgomery	20	0.0282	0.0349	0.4428
Grado 2	Todos	106	0.0257	0.0334	0.6823
Grado 2	Shenzhen	86	0.0258	0.0339	0.6220
Grado 2	Montgomery	20	0.0253	0.0314	0.5479
Media de train	Todos	106	0.0486	0.0593	-0.0006
Media de train	Shenzhen	86	0.0459	0.0568	-0.0616
Media de train	Montgomery	20	0.0600	0.0692	-1.1957
Mediana de train	Todos	106	0.0486	0.0593	-0.0005
Mediana de train	Shenzhen	86	0.0459	0.0568	-0.0604
Mediana de train	Montgomery	20	0.0601	0.0693	-1.2020

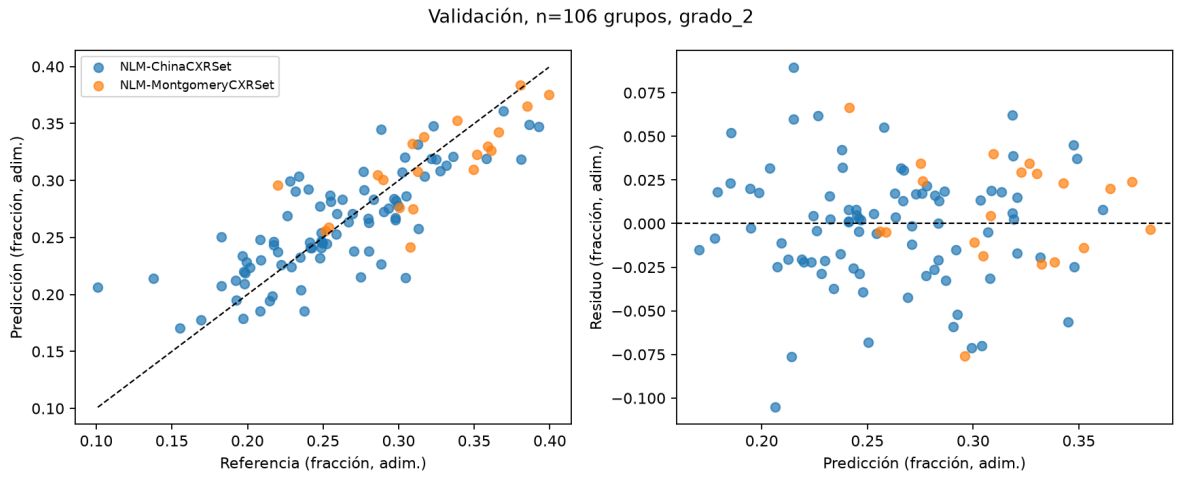


Figura 1: Validacion, 106 pacientes: referencia frente a prediccion y residuos frente a prediccion, por origen. Unidades: fraccion adimensional.

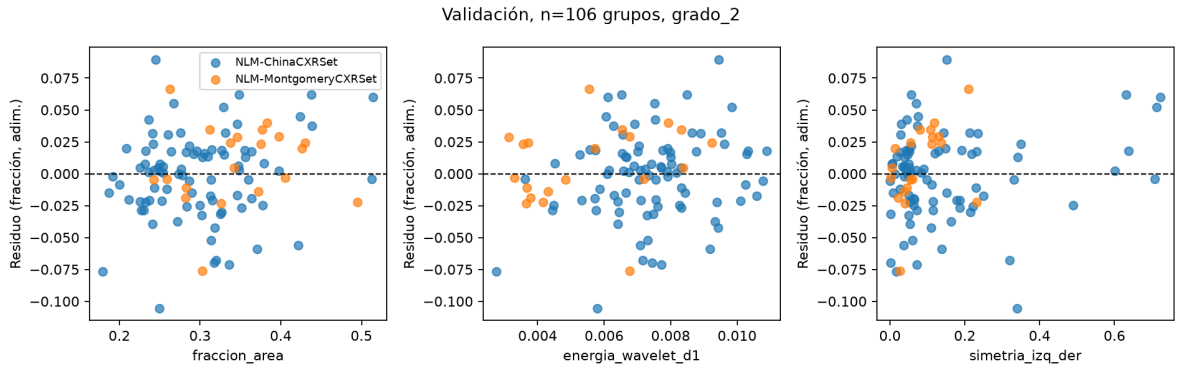


Figura 2: Validacion: residuos frente a cada predictor.

Cuadro 7: Coeficientes del modelo elegido, ajustado en train (predictores estandarizados con media y DE de train)

Termino	**Coeficiente**
intercepto	0.2800
fraccion_area	0.0465
energia_wavelet_d1	-0.0129
simetria_izq_der	-0.0220
fraccion_area^2	-0.0090
fraccion_area energia_wavelet_d1	-0.0024
fraccion_area simetria_izq_der	-0.0015
energia_wavelet_d1^2	-0.0006
energia_wavelet_d1 simetria_izq_der	0.0026
simetria_izq_der^2	0.0002

Los coeficientes se expresan por desviacion estandar de entrenamiento. `fraccion_area` domina, y los terminos cuadraticos y las interacciones son pequenos. Son asociaciones observa-

cionales: no indican que un descriptor cause la fraccion pulmonar.

5.2. Evaluacion unica en prueba

Cuadro 8: Metricas en la prueba, evaluada una sola vez con el modelo congelado

Modelo	Origen	n	MAE	RMSE	R2
Grado 2	Todos	99	0.0245	0.0312	0.6767
Grado 2	Shenzhen	79	0.0232	0.0290	0.6956
Grado 2	Montgomery	20	0.0294	0.0388	0.4081
Media de train	Todos	99	0.0444	0.0552	-0.0086
Media de train	Shenzhen	79	0.0428	0.0527	-0.0047
Media de train	Montgomery	20	0.0506	0.0641	-0.6095
Mediana de train	Todos	99	0.0444	0.0552	-0.0091
Mediana de train	Shenzhen	79	0.0428	0.0527	-0.0043
Mediana de train	Montgomery	20	0.0507	0.0641	-0.6137

En la prueba de 99 pacientes, el modelo alcanzo un RMSE de 0.0312 (MAE 0.0245), frente a 0.0552 de la media de entrenamiento: una reduccion del 43 % ($R^2 = 0{,}68$). El desempeno coincide con el de validacion ($R^2 = 0{,}68$), sin optimismo visible por la seleccion. El RMSE fue 0.0290 en Shenzhen ($n = 79$) y 0.0388 en Montgomery ($n = 20$). El residuo medio fue +0,0038 y +0,0039, respectivamente.

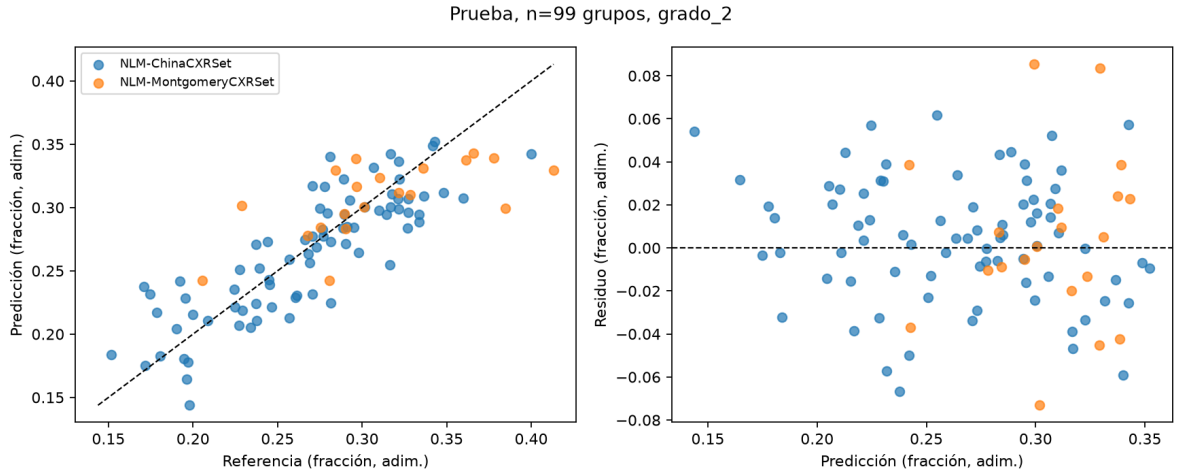


Figura 3: Prueba, 99 pacientes: referencia frente a prediccion y residuos.

6. Discusion y limites

- **Regresion a la media.** Las fracciones extremas se sobreestiman (las bajas) o se subestiman (las altas). El modelo es menos confiable en esos casos.
- **Efecto de centro.** La fraccion de referencia media en entrenamiento fue 0.317 en Montgomery y 0.260 en Shenzhen. La referencia constante falla sistematicamente en Mont-

gomery; el modelo corrige ese desfase con los descriptores. Montgomery aporta solo 20 pacientes en prueba, de modo que la comparacion entre centros es imprecisa. No se ha verificado el transporte a un tercer centro.

- **Denominador compartido.** `fraccion_area` y el objetivo se normalizan por el mismo campo irradiado. La asociacion no es circular, porque provienen de mascaras distintas, pero comparten ese componente.
- **Segmentaciones fallidas.** El modelo no aplica cuando la segmentacion automatica produce una sola componente.
- **Soporte de los predictores.** `simetria_izq_der` es muy asimetrica; en sus valores extremos hay pocos casos y el termino cuadratico extrapola.
- **Incertidumbre.** Se reportan estimaciones puntuales; no se calcularon intervalos por bootstrap.

7. Reproduccion y comprobaciones

Todo el flujo se reconstruye desde los datos originales con:

```
uv sync --locked
uv run ruff check .
uv run ruff format --check .
uv run pytest
uv run python scripts/reproduce.py
latexmk -pdf -interaction=nonstopmode -halt-on-error
        -outdir=build/reports reports/informe.tex
```

El entorno usa Python 3.13 con dependencias bloqueadas en `uv.lock`. El contrato registra el hash SHA-256 de la tabla de entrenamiento, y el protocolo congelado el de validacion; la prueba falla si alguno cambia. Una segunda ejecucion reprodujo exactamente las metricas de prueba.

Las pruebas automaticas verifican que:

- un paciente que cruce particiones produce error;
- el objetivo, los identificadores y las columnas derivadas de la mascara manual no pueden ser predictores;
- la imputacion aprende solo de entrenamiento;
- un objetivo faltante se excluye y no se imputa;
- las metricas coinciden con valores calculados a mano;
- dos ajustes iguales producen los mismos coeficientes.

8. Conclusion

En la prueba de 99 pacientes, la regresion polinomica de grado 2 sobre tres descriptores de la segmentacion automatica estimo la fraccion pulmonar de referencia con un RMSE de 0.0312, frente a 0.0552 de la media de entrenamiento. El error fue del mismo orden en ambos origenes, sin sesgo medio apreciable. El modelo regresa a la media en fracciones extremas, no se ha verificado su transporte a otro centro y no aplica cuando la segmentacion falla.