# Modelado supervisado con regresion multiple

## Estimacion de la fraccion pulmonar de referencia a partir de la segmentacion automatica

Juanita Trujillo Narvaez
Karol Isabella Martinez Villarreal

Ingenieria Biomedica
PSIM - 2026II - 80
Docente: Ing. Pablo Eduardo Caicedo-Rodriguez, Ph.D.

15 de octubre de 2026

# Problema, salida y protocolo

**Pregunta**

¿Los descriptores de la mascara *automatica* permiten estimar la fraccion pulmonar de la mascara *manual* en pacientes no usados para ajustar el modelo?

## Contrato

| | |
|---|---|
| Unidad | paciente (`grupo_id`) |
| Salida | `ref_fraccion_area` (adim.) |
| Referencia | mascara trazada por personas |
| Estrategia | `base_adap`, elegibles |
| Metrica | RMSE, fijada antes |
| Ruta binaria | no aplica: TB es control |

**Del EDA al protocolo** (solo train)

- Predictores por asociacion con el objetivo y signo consistente entre origenes: `fraccion_area` ($\rho = 0{,}70$), `energia_wavelet_d1` ($\rho = -0{,}51$), `simetria_izq_der` ($\rho = -0{,}23$)
- Excluidos: `ref_`, `err_`, Dice, Jaccard, IDs y origen
- Efecto de centro: fraccion media 0.317 (MC) frente a 0.260 (SH) $\Rightarrow$ errores por origen

| | Mascara | Elegibles | Pacientes |
|---|---|---|---|
| Train | 486 | 460 | 457 |
| Valid. | 110 | 106 | 106 |
| Prueba | 108 | 99 | 99 |

La prueba se extrajo **despues** de congelar el protocolo.

# Modelos y seleccion

**Candidatos** ($z_j$ estandarizado con train)

$$\text{G1: } \hat{y} = \beta_0 + \sum_j \beta_j z_j$$

$$\text{G2: } \hat{y} = \text{G1} + \sum_{j \le k} \beta_{jk} z_j z_k$$

Imputacion, escalamiento y expansion dentro del *pipeline*, ajustados solo en train. Referencia: media de train.

**Practica comun (sinteticos)**

- Continua: Grado 2 reconoce $x_0^2$; RMSE prueba 1.327 vs 3.872
- Binaria: AUC 0.81, AP 0.73 (prevalencia 0.42); sensibilidad 0.45 con umbral 0.5

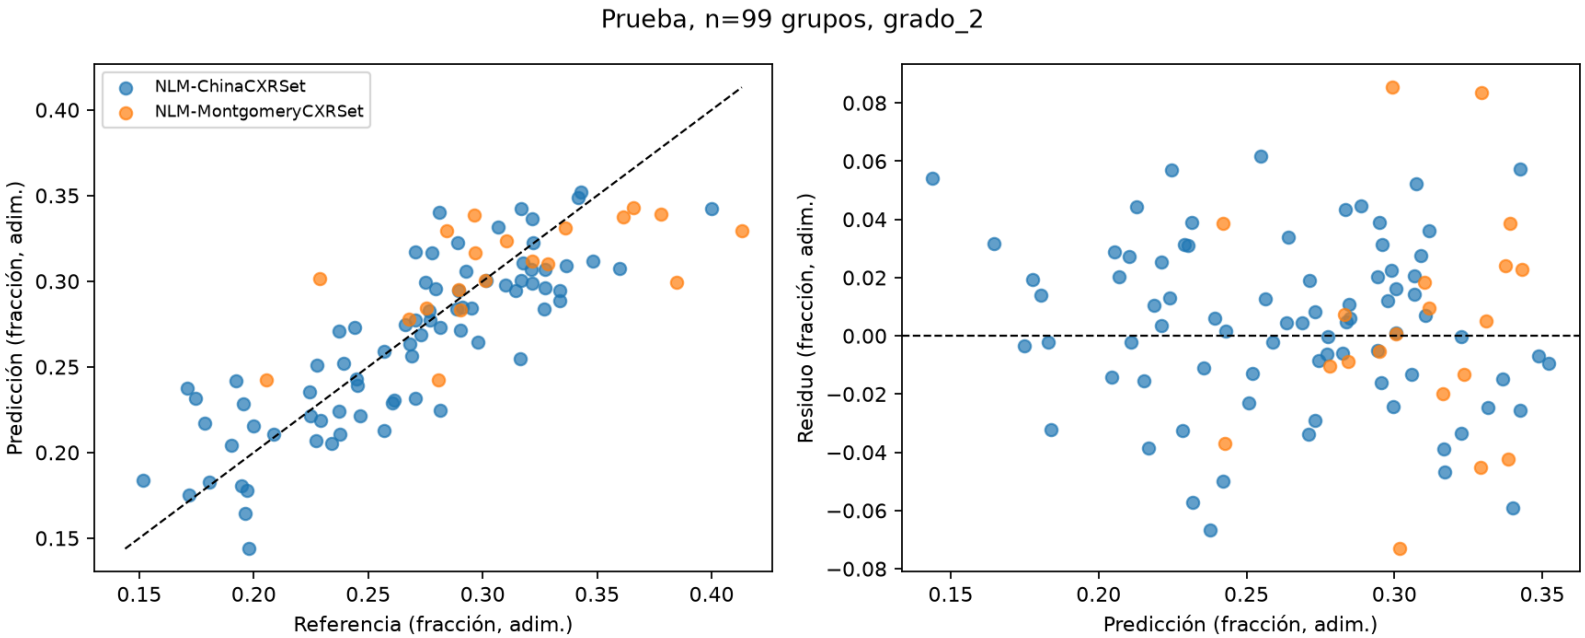
**Proyecto: validacion** ($n = 106$)

| Modelo | RMSE |
|---|---|
| Media de train | 0.0593 |
| Grado 1 | 0.0368 |
| **Grado 2** | **0.0334** |

Se elige **Grado 2** por la regla predeclarada. Su ventaja sobre grado 1 es modesta: casi todo el poder esta en el termino lineal.

Rango completo (10/10), condicion 8.7: coeficientes identificables. `fraccion_area` domina; las interacciones son pequenas. Asociacion, no causalidad.

# Resultados en prueba y diagnostico




**Evaluacion unica,** $n = 99$ **pacientes**
RMSE **0.0312** vs 0.0552 de la media (43 % menos), $R^2 = 0{,}68$, igual a validacion.
SH: 0.0290 ($n = 79$)  MC: 0.0388 ($n = 20$).
Residuo medio $+0{,}0038$ y $+0{,}0039$.

## Limites

- Regresion a la media en fracciones extremas
- Montgomery con pocos casos; sin tercer centro
- No aplica si la segmentacion falla (1 componente)
- Sin intervalos de incertidumbre

# Reproduccion y siguiente decision

## Un comando reconstruye todo

```
uv sync --locked
uv run ruff check .
uv run pytest
uv run python scripts/reproduce.py
```

### Comprobaciones automaticas

- Paciente que cruza particiones $\Rightarrow$ error
- Objetivo, IDs o `ref_` como predictor $\Rightarrow$ error
- Imputacion aprendida solo en train
- Hashes de train y validacion verificados
- Prueba reconstruida: coeficientes y metricas identicos

## Conclusion

Los descriptores automaticos estiman la fraccion pulmonar de referencia con error de 0.0312 en pacientes nuevos, del mismo orden en ambos centros.

### Siguiente decision

Calcular intervalos por bootstrap de pacientes y comparar el error con la variabilidad entre observadores, para decidir si la correccion es util en la practica.