

Estabilidad de los descriptores morfológicos del campo pulmonar frente a estrategias de preprocesamiento y segmentación en radiografías de tórax

Juanita Trujillo Narváez. Cod: 1000099467
Karol Isabella Martínez Villarreal. Cod: 1000099682

Ingeniería Biomédica

PSIM - 2026II - 80

Docente: Ing. Pablo Eduardo Caicedo-Rodríguez. Ph.D.

Fecha de entrega: 17 de septiembre de 2026

Índice

1. Planteamiento del problema	3
1.1. Mapa causal-operativo	3
2. Pregunta de investigación	5
3. Objetivos	6
3.1. Objetivo general	6
3.2. Objetivos específicos	6
3.3. Trazabilidad de los objetivos	7
4. Variables y criterio de éxito	8
5. Conjunto de datos	9
5.1. Matriz de decisión	9
5.2. Justificación de la selección	10
6. Diseño de las tres fases	11
6.1. Fase 1 — Formulación, adquisición y caracterización	11
6.2. Fase 2 — Procesamiento y extracción de características	12
6.3. Fase 3 — Integración, validación y presentación final	14
6.4. Correspondencia entre fases y objetivos	15
7. Cobertura de bloques técnicos	15
7.1. Técnicas evaluadas que no se espera conservar	16
7.2. Modelo estadístico	16
7.3. Estado y actualización	17
8. Cronograma	17
8.1. Reparto de responsabilidades	18
8.2. Riesgos y mitigación	20
9. Estructura reproducible	21
9.1. Dependencias	21
9.2. Estructura de carpetas	21
9.3. Política de datos	22
9.4. Verificación de integridad	22
9.5. Reproducción del proyecto	22

Resumen

Este documento presenta la formulación del proyecto semestral del curso Procesamiento de Señales e Imágenes Médicas. Se define el problema de la inestabilidad de los descriptores morfológicos del campo pulmonar en radiografías de tórax posteroanteriores frente a distintas estrategias de preprocesamiento y segmentación, se plantea la pregunta de investigación y los objetivos asociados, se documenta la selección del conjunto de datos entre cuatro candidatos evaluados, se traza la cobertura de los bloques técnicos de la asignatura, se define el cronograma de quince semanas con sus riesgos y mitigaciones, y se describe la estructura reproducible del proyecto.

1. Planteamiento del problema

La radiografía de tórax posteroanterior es una de las modalidades de imagen más prescritas en la práctica clínica. Cada píxel de la imagen representa la atenuación acumulada que sufre un haz de rayos X al atravesar el tórax [5], de modo que la imagen es una proyección bidimensional de un volumen tridimensional: el aire contenido en el parénquima pulmonar atenúa poco y se registra oscuro, mientras que el hueso y el mediastino atenúan considerablemente y se registran claros.

Sobre esa proyección, la delimitación del campo pulmonar es el paso previo a cualquier medición cuantitativa. Esa delimitación es inestable porque el contraste entre el pulmón y las estructuras vecinas depende de la tecnología del detector, de los parámetros de exposición y de la presencia de hallazgos que opacifiquen el parénquima. Los conjuntos públicos de la National Library of Medicine [4] hacen visible el problema: las imágenes de Montgomery se adquirieron con radiografía computarizada en doce bits, mientras que las de Shenzhen provienen de radiografía digital directa en ocho bits, con resolución variable y codificación de escala invertida.

Lo medible directamente en las imágenes es la intensidad de cada píxel y, a partir de la región segmentada, su área, su perímetro, su compacidad, su relación de aspecto y la simetría entre los campos derecho e izquierdo.

Si la máscara obtenida se desplaza según la estrategia de preprocesamiento aplicada, los descriptores morfológicos heredan esa variabilidad y dejan de ser comparables entre sujetos o entre sitios de adquisición, aun cuando la anatomía subyacente no haya cambiado.

Las técnicas del curso permiten cuantificar ese efecto de manera controlada: aplicar estrategias alternativas de realce, umbralización y morfología, medir su concordancia contra máscaras trazadas por expertos y estimar cuánto se desplaza cada descriptor morfológico respecto a su valor de referencia.

El proyecto no pretende detectar ni diagnosticar tuberculosis, no propone un método superior al estado del arte, no evalúa observadores humanos y no generaliza sus resultados a otras modalidades ni a otras proyecciones radiográficas.

1.1. Mapa causal-operativo

El esquema siguiente diferencia los siete elementos que exige la guía: las seis etapas de la cadena operativa, de la imagen original al resultado cuantitativo, y los factores de confusión técnicos que actúan sobre ellas. La cadena aparece en la figura y los factores en la tabla que la sigue, con las variables reales del proyecto en lugar de nombres genéricos.




Figura 1: Mapa causal-operativo del proyecto.

Cuadro 1: Factores de confusión técnicos y etapa sobre la que actúan.

Factor de confusión	Etapa	Efecto sobre la cadena
Tecnología del detector	2, 3, 4	La respuesta de contraste y la estructura del ruido difieren; un mismo umbral no produce la misma máscara en los dos orígenes
Profundidad de cuantización	2, 3	Las métricas de contraste sobre valores crudos no son comparables sin normalizar primero
Codificación de intensidad	1, 3	Sin corregir la inversión y los tres canales, el umbral segmenta el complemento del campo pulmonar
Ausencia de espaciado de píxel	5	Impide expresar área y perímetro en milímetros; obliga a que los cinco descriptores sean adimensionales
Dispersión de resolución espacial	2, 5	El perímetro y la compacidad son sensibles a la escala; obliga a fijar una resolución de trabajo común
Hallazgos que opacifican el parénquima	3, 4	Reducen el contraste del borde pulmonar y desplazan la máscara en los casos con manifestaciones
Convención de trazado de la referencia	6	Montgomery excluye corazón y grandes vasos, Shenzhen los delimita; introduce un sesgo sistemático entre orígenes que no puede corregirse

El punto del esquema es que el resultado cuantitativo de la etapa 6 no depende solo de la anatomía del sujeto, sino de las decisiones tomadas en las etapas 3 y 4 y de los factores que actúan sobre ellas. La pregunta de investigación indaga precisamente cuánto de la variación observada en los descriptores proviene de esas decisiones y no del sujeto.

2. Pregunta de investigación

¿En qué medida las estrategias de realce de intensidad, umbralización y morfología modifican la estabilidad de los descriptores morfológicos del campo pulmonar (compacidad, relación de aspecto, fracción de área, simetría izquierda-derecha), respecto a los descriptores obtenidos sobre la

máscara de referencia, en radiografías de tórax de los conjuntos Montgomery y Shenzhen de la National Library of Medicine?

3. Objetivos

3.1. Objetivo general

Evaluar el efecto de las estrategias de normalización, realce, umbralización y morfología sobre la estabilidad de los descriptores morfológicos del campo pulmonar en radiografías de tórax posteroanteriores de los conjuntos Montgomery y Shenzhen de la National Library of Medicine, mediante la comparación cuantitativa contra los descriptores derivados de máscaras de referencia trazadas por expertos, para determinar qué combinación de técnicas produce mediciones morfológicas reproducibles entre sitios de adquisición.

3.2. Objetivos específicos

- OE1.** Caracterizar las propiedades de digitalización y adquisición de ambos conjuntos: resolución espacial, profundidad de cuantización, número de canales, rango y distribución de intensidades. (*Fase 1*)
- OE2.** Comparar estrategias de normalización y reducción de ruido en dominio espacial y de frecuencia sobre una muestra controlada estratificada por origen y clase. (*Fases 1–2*)
- OE3.** Comparar estrategias de segmentación del campo pulmonar (umbral global, adaptativo, Otsu) combinadas con operaciones morfológicas, contra las máscaras de referencia. (*Fase 2*)
- OE4.** Cuantificar el desplazamiento de cada descriptor morfológico y de textura respecto a su valor de referencia bajo cada combinación de estrategias. (*Fases 2–3*)
- OE5.** Analizar si los descriptores obtenidos con la combinación seleccionada difieren entre imágenes con y sin hallazgos de tuberculosis, y documentar limitaciones y sensibilidad. (*Fase 3*)

3.3. Trazabilidad de los objetivos

Cuadro 2: Trazabilidad de los objetivos específicos a fase, producto y criterio.

OE	Fase	Producto verificable	Criterio de cumplimiento
OE1	1	docs/dataset_card.md, results/fase1/ caracterizacion.csv, figures/fase1/ histogramas.png	Las 800 imágenes con dimensiones, profundidad, canales y estadísticos registrados; identificadas y corregidas las de escala invertida
OE2	1-2	results/fase2/ metricas_realce.csv, figures/fase2/ realce_comparacion.png, figures/fase2/espectros.png	Cada estrategia con contraste RMS, desviación estándar del fondo y conservación de bordes; se conservan solo las que mejoran al menos una métrica sin degradar las otras
OE3	2	results/fase2/ dice_por_estrategia.csv, figures/fase2/mascaras.png	Dice y Jaccard por imagen sobre el conjunto de validación, reportados estratificados por origen
OE4	2-3	results/fase3/ tabla_caracteristicas.csv, figures/fase3/ error_descriptores.png	Error relativo mediano e intervalo intercuartílico por descriptor y estrategia; identificado el descriptor más estable
OE5	3	results/fase3/ analisis_estadistico.csv, informe final	in- Prueba de hipótesis definida a priori, con tamaño de efecto e intervalo de confianza; análisis de sensibilidad incluido

4. Variables y criterio de éxito

Cuadro 3: Definición de variables del estudio.

Elemento	Definición
Variable de entrada	Intensidad de píxel de la radiografía PA, más los parámetros de cada estrategia (tamaño de kernel, tipo de umbral, elemento estructurante, frecuencia de corte, nivel de descomposición)
Variable de salida	Descriptores morfológicos del campo pulmonar segmentado
Características a extraer	Compacidad, relación de aspecto, fracción de área respecto al campo de imagen, simetría entre campo derecho e izquierdo, energía por subbanda wavelet
Variable de comparación	Los mismos descriptores calculados sobre la máscara de referencia
Métrica principal	Error relativo de cada descriptor respecto a su valor de referencia
Métricas secundarias	Coefficiente Dice, índice de Jaccard, contraste RMS, desviación estándar del fondo, conservación de bordes
Unidad de análisis	La imagen. Ninguno de los conjuntos incluye identificador de paciente, de modo que la equivalencia entre imagen y sujeto es un supuesto que debe verificarse en Fase 1. Los objetivos OE3 y OE4 operan sobre el subconjunto de 704 imágenes con máscara, estratificado por origen
Criterio de éxito técnico	Identificar al menos una combinación cuyo error relativo mediano sea menor que el de la línea base sin procesamiento, en al menos tres de los cinco descriptores, de forma consistente en ambos orígenes
Limitación esperada	Las máscaras de referencia provienen de dos procedencias con convenciones distintas: las de Montgomery excluyen corazón y grandes vasos y las de Shenzhen los delimitan, lo que sesga sistemáticamente la comparación entre orígenes

Todos los descriptores son adimensionales a propósito, porque el conjunto Shenzhen no documenta espaciado de píxel y las medidas en milímetros no serían comparables entre los dos conjuntos.

5. Conjunto de datos

El proyecto utiliza los conjuntos Montgomery County CXR Set y Shenzhen Hospital CXR Set, publicados por la U.S. National Library of Medicine. Juntos suman 800 radiografías de tórax posteroanteriores, de las cuales 704 disponen de máscara de campo pulmonar trazada por personas. La ficha técnica completa, con identificación, contenido, variable de interés, limitaciones y protocolo de reproducibilidad, se encuentra en `docs/dataset_card.md`; la comparación de candidatos con sus dieciséis campos documentados está en `docs/datasets_candidatos.csv`.

La elección de dos conjuntos en lugar de uno responde directamente a la pregunta de investigación. Montgomery se adquirió mediante radiografía computarizada en doce bits; Shenzhen mediante radiografía digital directa en ocho bits, codificada en tres canales y con la escala de grises invertida. Esa diferencia entre sitios de adquisición no es un inconveniente del conjunto de datos: es la condición de comparación que hace medible la estabilidad de los descriptores.

5.1. Matriz de decisión

Cuadro 4: Calificación de los candidatos de 0 a 2 en cada criterio. La última columna corresponde a la pareja finalmente seleccionada.

Criterio	JSRT	MC	SH	CheX	MC+SH
Ajuste a la pregunta	1	1	1	0	2
Documentación	2	2	1	2	2
Licencia/acceso	1	2	2	1	2
Tamaño computacional	2	2	2	1	2
Metadatos y unidad de análisis	2	2	1	1	1
Cobertura de técnicas PSIM	1	1	2	0	2
Total (máx. 12)	9	10	9	5	11

JSRT: Japanese Society of Radiological Technology con máscaras SCR. MC: Montgomery County CXR Set. SH: Shenzhen Hospital CXR Set. CheX: CheXmask.

5.2. Justificación de la selección

El puntaje no decide por sí solo. Montgomery obtiene diez puntos por separado y la pareja once, pero la diferencia decisiva está en un único criterio: ninguno de los conjuntos individuales permite responder la pregunta planteada, porque todos provienen de un solo sitio de adquisición y la pregunta pide explícitamente determinar qué combinación produce mediciones reproducibles *entre* sitios. Un candidato con buen puntaje agregado que no puede responder la pregunta no es un candidato viable.

JSRT [6, 8] se descarta pese a tener las máscaras más completas del grupo, que incluyen pulmones, corazón y clavículas y habrían permitido calcular la relación cardiorrespiratoria. El acceso requiere solicitud y aprobación, y el cronograma de quince semanas no admite depender de un tiempo de respuesta que no controlamos. Es un descarte por riesgo de ejecución, no por calidad del conjunto.

CheXmask [3] se descarta por una razón metodológica que ningún puntaje compensa. Sus máscaras fueron generadas por un modelo de aprendizaje profundo, no trazadas por personas. Usarlas como referencia invalidaría el criterio de comparación del proyecto, que consiste precisamente en medir cuánto se aleja una segmentación automática de una referencia humana, y contravendría la restricción de no emplear Machine Learning. Se documenta su evaluación y descarte porque es el primer resultado que aparece al buscar máscaras para estos conjuntos.

La pareja Montgomery y Shenzhen se selecciona porque satisface las condiciones mínimas exigidas y porque su heterogeneidad es funcional al problema. Ambos son de descarga directa sin registro, están desidentificados bajo exención IRB, tienen procedencia y citación localizables, y suman 4.08 GB, un volumen manejable con los recursos del equipo. Montgomery aporta máscaras supervisadas por radiólogo para el cien por ciento de sus imágenes y documenta espaciado de píxel; Shenzhen aporta volumen, una tecnología de detector distinta y las particularidades de codificación que obligan a ejercitar conversión de espacio de color, corrección de inversión y normalización de rango dinámico.

La pareja no obtiene puntaje perfecto, y el criterio donde pierde es el que más importa vigilar. Ninguno de los dos conjuntos incluye identificador de paciente, de modo que la equivalencia entre imagen y sujeto es un supuesto que debe verificarse en Fase 1; Shenzhen no documenta espaciado de píxel, razón por la cual todos los descriptores del proyecto son adimensionales; y 96 de sus imágenes carecen de máscara, por lo que los objetivos OE3 y OE4 operan sobre el subconjunto de 704 casos con referencia, estratificado por origen. Estas tres limitaciones están declaradas antes de procesar los datos y acotan el alcance de las conclusiones.

6. Diseño de las tres fases

El proyecto se organiza en tres fases acumulativas: cada una deja productos que la siguiente consume. La Fase 1 entrega los datos caracterizados y el protocolo; la Fase 2 entrega las estrategias comparadas con evidencia cuantitativa; la Fase 3 reconstruye el flujo completo con las estrategias justificadas y responde la pregunta de investigación.

6.1. Fase 1 — Formulación, adquisición y caracterización

Cuadro 5: Productos esperados de la Fase 1 y su ubicación en el repositorio.

Producto esperado	Ubicación
Propuesta y pregunta de investigación	docs/formulacion_proyecto.tex
Ficha del conjunto de datos	docs/dataset_card.md
Procedimiento reproducible de descarga	data/raw/README.md y scripts/check_dataset.py
Inspección de formato, dimensiones, rango y metadatos	results/fase1/caracterizacion.csv
Análisis de muestreo, cuantización, resolución espacial e intensidad	figures/fase1/submuestreo.png, figures/fase1/requantizacion.png, figures/fase1/rango_intensidad.png
Caracterización de píxeles, vecindades, conectividad y regiones	src/psim/geometry.py, figures/fase1/conectividad.png, figures/fase1/distancia_borde.png
Estadísticas básicas e histogramas iniciales	figures/fase1/ histogramas.png, figures/fase1/ histogramas_comparados.png

Pregunta de control: ¿qué propiedades de la adquisición pueden afectar los resultados de las fases posteriores? Siete propiedades están identificadas antes de procesar los datos, y cada una tiene una consecuencia concreta sobre las fases siguientes.

1. **Tecnología del detector.** Montgomery se adquirió con radiografía computarizada y Shenzhen con radiografía digital directa. La respuesta de contraste y la estructura del ruido difieren, de modo que un mismo umbral no produce la misma máscara en los dos orígenes. Obliga a reportar toda métrica estratificada por sitio.

2. **Profundidad de cuantización.** Doce bits frente a ocho. Cualquier métrica de contraste calculada sobre valores crudos no es comparable entre orígenes sin normalizar primero el rango dinámico.
3. **Codificación de intensidad.** Las imágenes de Shenzhen vienen en tres canales RGB y con la escala de grises invertida. Sin corregir ambas cosas, cualquier umbral segmenta el complemento de lo que se busca.
4. **Ausencia de espaciado de píxel en Shenzhen.** Impide expresar área o perímetro en milímetros. Es la razón por la cual los cinco descriptores del proyecto son adimensionales.
5. **Dispersión de resolución espacial.** Montgomery es homogéneo en torno a 4020x4892 píxeles; Shenzhen varía alrededor de 3000x3000. Descriptores sensibles a la escala, como el perímetro, se ven afectados, lo que obliga a fijar una resolución de trabajo común y a verificar con submuestreo controlado que esa reducción no altera los descriptores.
6. **Convención de trazado de la máscara de referencia.** Las máscaras de Montgomery excluyen corazón y grandes vasos [1]; las de Shenzhen los delimitan [7]. Es un sesgo sistemático entre orígenes que no puede corregirse y que se declara como la principal limitación del estudio.
7. **Archivos anómalos.** Nueve imágenes de Shenzhen pesan menos de 2 MB frente a un promedio de 5.43 MB, lo que sugiere resolución o codificación distinta. Deben identificarse en la caracterización y decidirse explícitamente si se conservan o se excluyen, con el criterio documentado.

6.2. Fase 2 — Procesamiento y extracción de características

La Fase 2 implementa de forma reproducible los bloques de intensidad, vecindad, histogramas, bordes, umbralización, morfología, dominio de frecuencia y wavelets [2] definidos en la matriz de técnicas. Ninguna comparación se resuelve por apariencia: cada una se decide con una de las métricas definidas a continuación, fijadas antes de ejecutar el procesamiento.

Cuadro 6: Métricas de decisión de la Fase 2.

Métrica	Definición operativa
Contraste RMS	Desviación estándar de la intensidad normalizada dentro de la región torácica. Mide si el realce separa mejor el parénquima del fondo.
Desviación del fondo	Desviación estándar en una región de aire fuera del paciente. Mide ruido residual: un filtro útil la reduce.
Conservación de borde	Razón entre la magnitud media del gradiente sobre el contorno de referencia antes y después del filtrado. Un valor cercano a uno indica que el filtro no difuminó el borde.
Coefficiente Dice	Solapamiento entre la máscara obtenida y la de referencia. Métrica principal de segmentación.
Índice de Jaccard	Solapamiento alternativo, más severo con errores de área. Se reporta junto al Dice.
Estabilidad de área y perímetro	Variación del área y el perímetro de la máscara entre estrategias, respecto a la referencia.
Energía espectral por banda	Fracción de energía del espectro en bandas radiales. Permite comparar filtrado en frecuencia contra filtrado espacial.
Energía por subbanda wavelet	Energía de los coeficientes de detalle por nivel. Sirve como descriptor de textura y como comparación entre orígenes.

El trabajo de esta fase procede sobre una muestra controlada estratificada por origen y por clase antes de extenderse al conjunto completo, para que los parámetros se ajusten sin recorrer 800 imágenes en cada iteración. Los productos acumulables son las tablas de métricas por estrategia en `results/fase2/`, los paneles comparativos en `figures/fase2/` y los módulos de `src/psim/` que implementan cada bloque.

6.3. Fase 3 — Integración, validación y presentación final

Cuadro 7: Requisitos de la Fase 3 y forma de cumplimiento.

Requisito	Cumplimiento previsto
Reconstruir el flujo completo desde los datos originales	<code>scripts/reproduce.py</code> parte de <code>data/raw/</code> y regenera todo producto derivado
Seleccionar las transformaciones justificadas por la Fase 2	La selección se toma de <code>results/fase2/</code> , no por criterio visual; la matriz de técnicas se actualiza a <code>conservado</code> o <code>descartado</code> con el valor que sustenta la decisión
Obtener las características finales	<code>results/fase3/tabla_caracteristicas.csv</code>
Responder la pregunta de investigación	Comparación del error relativo mediano por descriptor y estrategia contra la línea base sin preprocesamiento, en ambos orígenes
Aplicar análisis estadístico	Estadística descriptiva, estimación de distribuciones y prueba de hipótesis entre grupos, con tamaño de efecto e intervalo de confianza
Regresión logística o polinómica	No planeada. La pregunta es descriptiva y comparativa, no predictiva; la decisión queda documentada en la matriz de técnicas
Análisis de sensibilidad y limitaciones	Variación de los parámetros de la combinación seleccionada para verificar que la conclusión no depende de un ajuste particular, más las limitaciones declaradas en la ficha del conjunto de datos
Regenerar tablas y figuras mediante código	Ninguna figura ni tabla del informe final se edita a mano; todas se producen desde <code>src/psim/</code> y se escriben en <code>figures/</code> y <code>results/</code>
Presentar el proyecto en el Laboratorio 03	<code>docs/sustentacion.tex</code> , semana 15

6.4. Correspondencia entre fases y objetivos

Cuadro 8: Distribución de los objetivos específicos entre las tres fases.

Objetivo	Fase 1	Fase 2	Fase 3
OE1	completo	—	—
OE2	inicia	completa	—
OE3	—	completo	—
OE4	—	inicia	completa
OE5	—	—	completo

De las 53 técnicas de la matriz, 14 corresponden a la Fase 1, 30 a la Fase 2 y 9 a la Fase 3.

7. Cobertura de bloques técnicos

La matriz completa está en `docs/matriz_tecnicas.csv`, con 53 filas y once columnas: bloque, técnica, fase, entrada, parámetros, producto, métrica, decisión esperada, archivo de código, figura o tabla, y estado. Cada fila responde las cuatro preguntas de trazabilidad: qué entrada recibe la técnica, qué parámetro se modifica o estima, qué producto genera y qué evidencia permitirá decidir si aporta al problema.

Cuadro 9: Distribución de las técnicas por bloque y fase.

Bloque	N	F1	F2	F3	Módulo
Representación y digitalización	9	9	—	—	<code>io.py</code> , <code>geometry.py</code>
Espacios e intensidad	5	3	2	—	<code>color.py</code>
Operaciones de vecindad	9	—	9	—	<code>spatial.py</code>
Histogramas	5	2	3	—	<code>histogram.py</code>
Umbralización y morfología	10	—	10	—	<code>segmentation.py</code>
Dominio de frecuencia	5	—	5	—	<code>frequency.py</code>
Wavelets y multirresolución	4	—	1	3	<code>wavelets.py</code>
Características y estadística	5	—	—	5	<code>features.py</code> , <code>stats.py</code>
Modelo estadístico opcional	1	—	—	1	<code>stats.py</code>
Total	53	14	30	9	

7.1. Técnicas evaluadas que no se espera conservar

Cobertura completa no significa encadenar operaciones arbitrariamente. Seis técnicas se incluyen como experimentos controlados, con la expectativa explícita de descartarlas si la evidencia no las respalda. Ese descarte es un resultado del proyecto siempre que esté sustentado cuantitativamente.

Cuadro 10: Técnicas con descarte previsto y criterio de decisión.

Técnica	Criterio de decisión
Filtro de media	Se descarta si degrada el borde más que la mediana con igual reducción de ruido
Prewitt	Se descarta si no supera a Sobel en concordancia con el borde de referencia
Roberts	Se descarta si resulta más sensible al ruido que los otros operadores
Emboss	Experimento direccional; no se espera que forme parte del flujo final
Top-hat	Experimento de realce de costillas; se conserva solo si mejora la separación del campo pulmonar
Espacio HSV	Se descarta si la saturación resulta nula, lo que confirmaría que las imágenes de Shenzhen son escala de grises replicada en tres canales

7.2. Modelo estadístico

La matriz incluye una fila para regresión logística con estado `no_planeado`. La guía la ofrece como opción y este proyecto no la ejecuta: la pregunta de investigación es descriptiva y comparativa, no predictiva. El objetivo OE5 compara los descriptores entre imágenes con y sin hallazgos de tuberculosis mediante prueba de hipótesis, con tamaño de efecto e intervalo de confianza, y el resultado se reporta como caracterización morfométrica. En ningún caso se presenta como detección, tamizaje ni diagnóstico. La fila se conserva en la matriz para dejar constancia de que la opción fue evaluada y descartada por razones metodológicas, no por omisión.

7.3. Estado y actualización

Las 53 filas están en estado **planeado**, salvo la de regresión logística. Conforme avanza el desarrollo, cada fila pasa a **conservado** o **descartado**, acompañada del valor de la métrica que sustenta la decisión. La matriz es, por tanto, un documento vivo: su estado final en la semana 15 constituye el registro de qué técnicas del curso aportaron al problema y cuáles no, con la evidencia de cada caso.

8. Cronograma

El cronograma completo, con dependencias, responsables, evidencias y estado por semana, está en `docs/cronograma.csv`. La tabla siguiente lo resume.

Cuadro 11: Cronograma semestral. L indica liderazgo y R revisión.

Sem.	Actividad	Responsable	Fase
1	Formulación del problema y pregunta	Karol L / Juanita R	1
2	Comparación y selección del conjunto de datos	Juanita L / Karol R	1
3	Ficha del dataset y procedimiento de descarga	Juanita L / Karol R	1
4	Descarga, verificación y caracterización	Juanita L / Karol R	1
5	Píxeles, conectividad, regiones; cierre Fase 1	Juanita L / Karol R	1
6	Intensidad, normalización y transformaciones	Karol L / Juanita R	2
7	Vecindad: filtros de ruido y operadores de borde	Juanita L / Karol R	2
8	Histogramas, ecualización y especificación	Karol L / Juanita R	2
9	Umbralización y morfología contra referencia	Karol L / Juanita R	2
10	Dominio de frecuencia y CWT sobre perfil 1D	Juanita L / Karol R	2
11	DWT 2D, energía por subbanda; cierre Fase 2	Karol L / Juanita R	2
12	Reconstrucción del flujo desde <code>data/raw/</code>	Juanita L / Karol R	3
13	Descriptores y error relativo frente a referencia	Juanita L / Karol R	3
14	Análisis estadístico y de sensibilidad	Juanita L / Karol R	3
15	Regeneración limpia, informe y Laboratorio 03	Karol L / Juanita R	3

8.1. Reparto de responsabilidades

Cada bloque técnico tiene una integrante que lo lidera y otra que lo revisa, alternándose entre bloques. La revisión no es un trámite: la revisora ejecuta el código y debe poder explicar cada decisión tomada. El propósito es que ninguna parte del proyecto dependa del conocimiento de una sola persona. Adicionalmente, Juanita man-

tiene la infraestructura reproducible (repositorio, entorno, `scripts/check_dataset.py` y `scripts/reproduce.py`) y Karol mantiene el documento y la coherencia entre resultados y narrativa.

8.2. Riesgos y mitigación

Cuadro 12: Riesgos identificados, indicadores tempranos y respuesta prevista.

Riesgo	Prob.	Impacto	Indicador temprano	Mitigación
Conjunto de datos no descargable	Baja	Alto	El índice del servidor de la NLM no responde o cambian las rutas en la semana 3	Ambos conjuntos existen en réplicas independientes (Internet Archive y el conjunto combinado de Mendeley con DOI 10.17632/8gf9vpkhgy.2). Se descarga en la semana 3, no en la 4, para dejar margen de reacción
Máscaras de Shenzhen inaccesibles	Media	Alto	El repositorio de Kaggle deja de estar disponible o cambia de licencia	El mismo conjunto de máscaras está en Mendeley con DOI versionado. Si ninguna fuente está disponible, OE3 y OE4 se restringen a Montgomery y se declara el cambio de alcance en el informe
Metadatos insuficientes para definir la unidad de análisis	Alta	Medio	Las lecturas clínicas no contienen identificador de paciente, confirmado en la semana 4	Se declara explícitamente el supuesto de una imagen por sujeto, se documenta como limitación y no se aplica ningún procedimiento que requiera partición por paciente
Tamaño computacional excesivo	Media	Medio	El procesamiento de una imagen de Montgomery a resolución plena supera el tiempo o la memoria disponible en la semana 6	La Fase 1 incluye submuestreo controlado para fijar una resolución de trabajo que no altere los descriptores. La Fase 2 opera primero sobre muestra estratificada. El procesamiento es imagen por imagen, nunca cargando el conjunto completo
Discrepancia entre las máscaras de referencia de los dos orígenes	Alta	Alto	El Dice de una misma estrategia difiere sistemáticamente entre orígenes en la semana 9	Toda métrica se reporta estratificada por sitio desde el comienzo. El criterio de éxito exige consistencia en ambos orígenes, no un promedio agregado. La diferencia de convención de trazado está declarada como limitación principal
Ninguna estrategia supera la línea base	Media	Medio	Los errores relativos de la semana 13 no mejoran respecto al procesamiento nulo	Es un resultado válido y se reporta como tal. La pregunta indaga en qué medida las estrategias modifican la estabilidad, no presupone que la mejoren. El análisis de sensibilidad documenta el rango de parámetros explorado
Retraso acumulado en la Fase 2	Media	Alto	El cierre de la semana 11 llega sin las métricas de wavelets	Las técnicas marcadas como experimento controlado (emboss, top-hat, pasa-banda) se ejecutan con parámetros únicos y sin barrido, o se documentan como no ejecutadas con la razón. Los bloques del flujo principal tienen prioridad

9. Estructura reproducible

El proyecto se administra con `uv`. Las dependencias se declaran en `pyproject.toml` y sus versiones exactas quedan fijadas en `uv.lock`. El entorno virtual no se versiona. La reconstrucción completa desde un repositorio limpio requiere Python 3.12 y un solo comando:

```
uv sync --locked
```

9.1. Dependencias

Se declaran siete bibliotecas de análisis: `numpy`, `scipy`, `matplotlib`, `pandas`, `scikit-image`, `pywavelets` y `statsmodels`; más `pytest` y `ruff` como dependencias de desarrollo. No se instala ningún paquete con `pip` dentro del entorno del proyecto.

La guía del curso incluye `opencv-python` en su comando de ejemplo. Este proyecto no lo declara. La razón es que las 53 técnicas de la matriz de cobertura son realizables con `scikit-image` y `scipy`: la ecualización adaptativa, el umbral de Otsu, el umbral adaptativo local, las operaciones morfológicas incluidas `top-hat` y `black-hat`, y los operadores de Sobel, Prewitt, Roberts y Laplaciano están disponibles en esas dos bibliotecas. El filtro de Butterworth se construye directamente sobre la transformada de Fourier de `scipy`, lo que además hace explícito el diseño del filtro en lugar de delegarlo. Agregar una dependencia sin uso concreto en el diseño metodológico contradice la advertencia de la propia guía, de modo que la omisión es deliberada y queda documentada aquí y en el `README.md`.

9.2. Estructura de carpetas

```
psim-proyecto/
|-- .python-version      Python 3.12
|-- .gitignore
|-- README.md           Protocolo de reconstruccion
|-- pyproject.toml       Dependencias declaradas
|-- uv.lock              Versiones fijadas
|-- data/
|   |-- raw/             Datos originales, no versionados
|   |   \-- README.md    Descarga y verificacion
|   \-- processed/       Datos derivados, regenerables
|-- docs/                Informe, ficha, matriz y cronograma
|-- figures/fase1..3/     Figuras por fase
```

```
|-- results/fase1..3/      Tablas y metricas por fase
|-- scripts/
|   |-- check_dataset.py   Verificacion de integridad
|   \-- reproduce.py      Reconstruccion completa
|-- src/psim/              Codigo reusable
\-- tests/
```

El código reusable vive en `src/psim/` y se separa de los guiones de ejecución en `scripts/`. Todas las rutas se construyen con `pathlib` y son relativas a la raíz del proyecto, de modo que el código funciona en Windows, Linux y macOS sin modificación.

9.3. Política de datos

Los datos originales son de solo lectura. Nada de lo que hay bajo `data/raw/` se sobrescribe. Todo cambio de tamaño, intensidad, formato, región de interés, filtro o máscara produce un dato derivado en `data/processed/` o un resultado regenerable en `results/` y `figures/`.

Las condiciones de uso de ambos conjuntos incluyen no redistribuirlos fuera del grupo de investigación, por lo que las imágenes no se versionan. En su lugar, `data/raw/README.md` documenta de dónde se obtienen, qué versión usar, qué archivos descargar y cómo verificar que la copia corresponde al conjunto descrito en la propuesta.

9.4. Verificación de integridad

El guion `scripts/check_dataset.py` comprueba que las siete colecciones de datos existan con los conteos esperados, verifica el tamaño total contra las cifras registradas en el índice del servidor de la NLM, calcula el hash SHA-256 de cada archivo y escribe `results/fase1/manifiesto_datos.csv`. Ese manifiesto es el único producto derivado que se versiona: permite comprobar que dos copias del conjunto son idénticas sin redistribuir las imágenes. Si algún conteo o tamaño no coincide, el guion no escribe el manifiesto y explica qué falta.

9.5. Reproducción del proyecto

El guion `scripts/reproduce.py` regenera todos los productos derivados a partir de `data/raw/`. Ninguna tabla ni figura del informe se edita a mano: todas se produ-

cen desde el código y se escriben en `results/` y `figures/`. La secuencia completa de verificación es:

```
uv sync --locked
uv run ruff check src/ scripts/
uv run pytest
uv run python scripts/check_dataset.py
uv run python scripts/reproduce.py
```

Referencias

- [1] Sema Candemir, Stefan Jaeger, Kannappan Palaniappan, Jonathan P. Musco, Rahul K. Singh, Zhiyun Xue, Alexandros Karargyris, Sameer Antani, George Thoma, and Clement J. McDonald. Lung segmentation in chest radiographs using anatomical atlases with nonrigid registration. *IEEE Transactions on Medical Imaging*, 33(2):577–590, 2014.
- [2] Geoff Dougherty. *Digital Image Processing for Medical Applications*. Cambridge University Press, 2009.
- [3] Nicolás Gaggion, Candelaria Mosquera, Lucas Mansilla, Juan M. Saidman, Martina Aineseder, Diego H. Milone, and Enzo Ferrante. CheXmask: a large-scale dataset of anatomical segmentation masks for multi-center chest x-ray images. *Scientific Data*, 11, 2024.
- [4] Stefan Jaeger, Sema Candemir, Sameer Antani, Yi-Xiang J. Wang, Pu-Xuan Lu, and George Thoma. Two public chest X-ray datasets for computer-aided screening of pulmonary diseases. *Quantitative Imaging in Medicine and Surgery*, 4(6):475–477, 2014.
- [5] Jerry L. Prince and Jonathan M. Links. *Medical Imaging Signals and Systems*. Pearson, 2 edition, 2015.
- [6] Junji Shiraishi, Shigehiko Katsuragawa, Junpei Ikezoe, Tsuneo Matsumoto, Takeshi Kobayashi, Ken-ichi Komatsu, Mitate Matsui, Hiroshi Fujita, Yoshie Kodaera, and Kunio Doi. Development of a digital image database for chest radiographs with and without a lung nodule. *American Journal of Roentgenology*, 174(1):71–74, 2000.
- [7] Sergii Stirenko, Yuriy Kochura, Oleg Alienin, Oleksandr Rokovyi, Yuri Gordienko, Peng Gang, and Wei Zeng. Chest X-ray analysis of tuberculosis by deep

learning with segmentation and augmentation, 2018. Conjunto de máscaras de campo pulmonar del conjunto Shenzhen, Instituto Politécnico de Kiev. Licencia CC BY-NC-SA 4.0.

- [8] Bram van Ginneken, Mikkil B. Stegmann, and Marco Loog. Segmentation of anatomical structures in chest radiographs using supervised methods: a comparative study on a public database. *Medical Image Analysis*, 10(1):19–40, 2006.